AI ENGINEERING PORTFOLIO

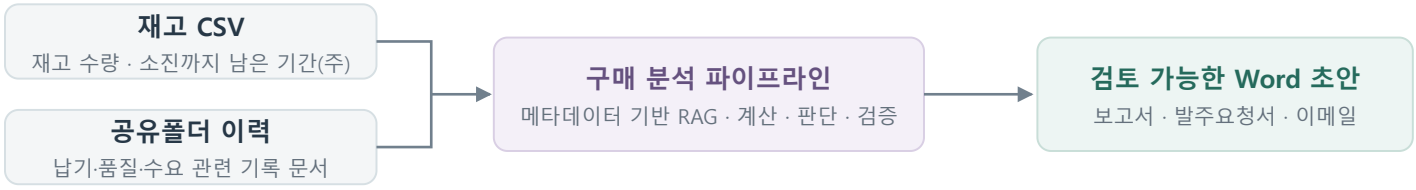
구매 의사결정 지원 멀티 에이전트 AI 시스템

Multi-agent Purchasing AI Suite

재고 CSV와 공급업체·품목 이력을 분석해
구매 분석보고서·발주요청서·공급처 이메일 초안을 생성합니다.

명수민 · AI Engineer · 기획·설계·개발·운영

> 재고 데이터에 **축적된 품목·공급업체 이력을 결합**해 납기·품질·수요 변화를 함께 분석하고, 맥락과 근거를 갖춘 구매 판단을 지원합니다.



코드·LLM 역할 분리	이력 자료 조회	문서별 자동 검증	용도별 모델 선정	실행 시간·비용
계산은 코드, 판단은 LLM	**메타데이터 기반 RAG**	**36개 검사 항목**	**모델별·effort별 측정**	**약 80초 · $0.05**
코드: 수치 계산·이력 조회·문서 조립 LLM: 이력 해석·문장 작성	업체·품목·날짜 헤더로 관련 이력만 정확히 조회	코드·LLM Judge 자동 검증 피드백 기반 재작성(최대 2회)	동일 입력 실행 → 기준별 판정 → 직접 검토(HITL) 후 채택	공급업체 1곳 품목 7개 기준

01 개발 배경

연 매출 약 £89M(2025년 6월 결산 기준) 규모 식품 유통 기업 Korea Foods에서 **구매팀**은 수만 개 품목의 재고 흐름 모니터링과 발주를 맡아 **늘 시간이 부족했습니다.** 이 때문에 업체·품목·날짜 헤더로 잘 정리된 공급처·제품 이력을 발주 판단 때 충분히 찾아 분석하지 못했고, 이는 **협상력 저하**로 이어질 수 있었습니다. 그래서 **AI의 빠른 자료 조회·분석 속도를 활용**해 이 이력을 재고 데이터와 결합하고, 근거를 갖춘 구매 판단을 지원하려고 개발했습니다. 이제 구매담당자는 관련 공급처·제품 이력을 직접 찾아 읽고 분석을 수행한 뒤 문서까지 작성하느라 몇 시간이 걸릴지 모르던 작업을, 이 솔루션으로 **공급업체당 약 80초 만에 처리**하고, 바로 활용 가능한 **분석보고서·발주요청서·공급처 이메일 초안**까지 받아볼 수 있습니다.

02 업무 단계별·현업 맞춤형 문서 생성

구매담당자는 SAP 사용자 쿼리로 품목코드를 넣어 조회한 결과를 CSV로 내보내(품목코드·품목명·공급업체, 가용 재고, 소진까지 남은 주수) **업로드하고 실행만 하면, 각 문서의 Word 초안**을 받습니다. 읽는 사람의 역할과 필요한 정보에 맞춰 **구매 담당자·결재권자·공급처용 문서를 따로 생성**합니다. 발주·협상·문의가 공급업체 단위로 이뤄지므로, 품목을 **공급업체별로 묶어 분석하고 문서를 생성**합니다.

01 / 구매 담당자

구매 분석보고서

재고 분석과 이력 출처, 담당자·공급처 확인 질문, 구매담당자에게 권고할 후속 조치를 제공합니다.

02 / 결재권자

발주요청서

구매 목적·사유와 품목표를 작성합니다. 미해결 질문·후속 조치는 문서 상단 임시 메모에 남겨, 해결 후 문서 수정·메모 삭제를 안내합니다.

03 / 공급처

이메일 초안

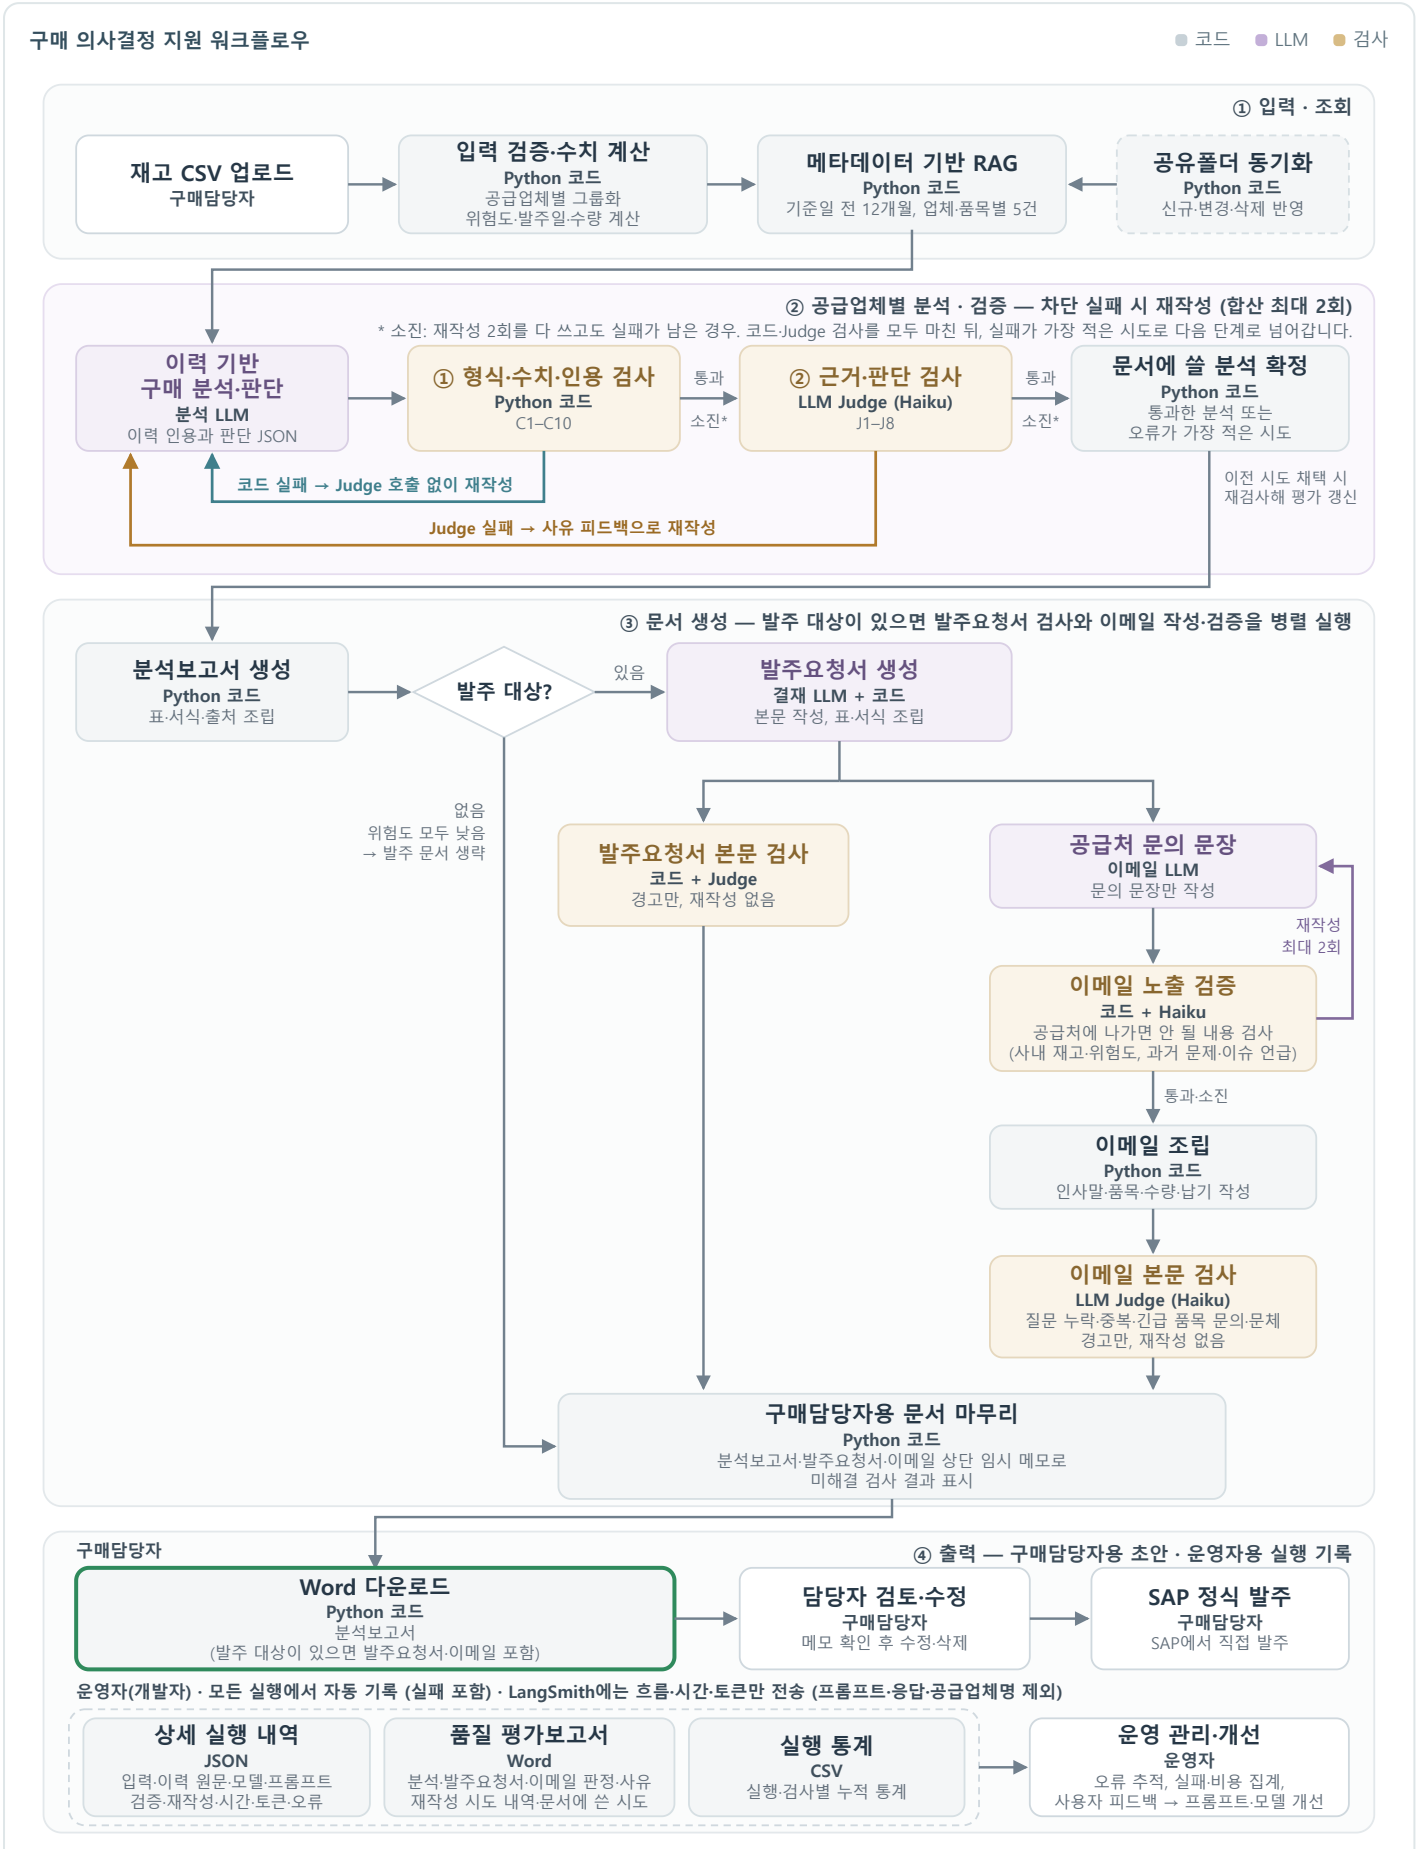
공급처에 주문 수량·요청 납기·확인할 사항을 전달합니다. 내부 재고·위험도·분석 내용 등 사내 민감정보의 외부 노출을 검사합니다.

분석 결과 모든 품목의 재고 위험도가 낮으면 발주요청서·이메일은 생략합니다. 담당자가 초안을 검토·수정하고, 정식 발주는 SAP에서 진행합니다(자세한 파이프라인 및 검증 기준은 2~4페이지 후술 참조).

Korea Foods 재직 중 개발·시범 운영한 시스템을 기반으로, 이후 개인 프로젝트로 아키텍처·평가·모델을 고도화했습니다. 공개 데모·평가는 합성 데이터를 사용합니다.

입력부터 문서 출력까지의 전체 실행 파이프라인

입력·조회 → 분석·검증 → 분석 확정 → 문서 생성·검증 병렬 처리 → 상단 임시 메모 → 구매담당자용 초안 · 운영자용 실행 기록.



근거를 추적하고 품질을 관리하는 설계

수치 계산·문서 조립은 **코드**가, 이력 기반 구매 판단·수신자별 문장 작성은 **LLM**이 담당합니다.

01 역할 분리와 근거 추적

담당	역할
코드	입력 검증·위험도·주문량·발주일 계산, 이력 검색, 문서 표·서식·출처 표시 조립
LLM	이력 사실 정리, 조달 기간·주문량 변경 제안, 확인 질문·후속 조치 권고, 본문 작성

근거 추적 체계: 원문 문서 [1], [2]... → 확인 사실 [F1], [F2]... → 변경 제안·확인 질문·권고 후속 조치. 문서에서 언급되는 사실에는 근거 문서 번호를, 제안·질문·조치에는 근거 사실 번호를 달고, 재고 수치에서 도출한 사실은 문서 번호 없이 별도 항목으로 묶습니다. 코드는 참조 누락·연결 구조를, LLM Judge는 인용 근거와 판단의 논리적 연결을 검사합니다.

재고 위험도 산정 기준 · W = 재고 소진까지 남은 기간(주), L = 조달 기간(기본 18주)
W<L: Critical · W<L+8: High · W<L+17: Medium · 그 외: Low. 앞 조건부터 순서대로 적용합니다.

01 / 메타데이터 기반 RAG

문서 헤더의 업체·품목·코드와 날짜로 검색합니다. 입력 재고 기준일 이전 12개월, 업체·품목별 최신 5건을 조회합니다. A4 1~2페이지 원문을 분할 없이 제공하고 공유폴더의 신규·변경·삭제를 동기화합니다.

02 / 수치 일관성

기본 조달 기간 18주, 권장 주문량은 입고 후 26주 판매량 기준입니다. LLM의 조달 기간 변경 제안을 반영해 **위험도·발주일·재고 부족 기간을 코드로 재계산**하고 LLM 수치와 대조합니다. 문서 표도 코드로 조립합니다.

03 / 이메일 가드레일

내부 정보(재고·위험도)와 공급처에 묻지 않을 질문은 **LLM 입력에서 제외**합니다. 수량·날짜는 코드로 조립합니다. 코드·별도 LLM으로 사내 민감정보·과거 공급처 문제·주문 외 품목의 **노출을 검사**합니다.

02 검증 결과와 실행 기록의 활용

품질 평가보고서: 분석·발주요청서·이메일의 검사 판정과 사유, 분석 재작성 시도별 결과를 기록합니다. 문서에 쓴 시도도 함께 남깁니다. 품질 평가보고서는 운영자용으로 서버에 저장됩니다.

검토 메모 자동 삽입: 코드가 분석보고서·발주요청서·이메일 초안 상단에 각 문서의 미해결 검사 결과를 임시 메모로 남깁니다. 분석 검사 결과는 분석을 근거로 작성한 발주요청서에도 함께 표시합니다. 모든 품목이 Low라 분석보고서만 나가도, 그 결론이 미해결 검사에 기대고 있으면 알 수 있습니다. 담당자는 다운로드 후 메모를 확인하고 필요한 조치·문서 수정을 수행합니다.

재작성 후에도 실패한 분석: 분석은 차단 항목 실패 시 재작성하되, 시간·비용이 끝없이 늘지 않도록 최대 2회로 제한합니다. 재작성이 오히려 나빠질 수도 있어, 재작성 2회 시도 후에도 실패하면 모든 시도 중 차단 실패가 가장 적은 시도로 문서를 만듭니다. 이 시도는 Judge 검사를 건너뛰었을 수 있어 코드·Judge로 다시 검사해 평가보고서와 메모를 갱신합니다.

실행 기록(JSON·CSV): 품질 평가보고서와 별도로, **실행마다 상세 로그를 JSON 파일로** 사내 서버에 남깁니다(실패한 실행 포함). 받은 CSV 원문, 모델이 읽은 이력 문서, 모델·프롬프트 버전, 모든 출력과 검사 결과, 단계별 시간·토큰·오류가 담겨 실행을 사후에 설명할 수 있습니다. **실행·검사별 통계는 CSV에 누적**해 버전별 실패·재작성·비용 집계에 씁니다. 회사 데이터는 이 기록에만 남깁니다.

LangSmith: 개발에서는 합성 데이터로 파이프라인 테스트·프롬프트 비교에, 운영에서는 시간·토큰·비용·실패 추이 모니터링에 씁니다. 이때는 실행 흐름·시간·토큰·모델명만 보내고 프롬프트·응답 본문은 항상 숨기며, 숨김으로 가려지지 않는 실행 이름·메타데이터의 공급업체명은 코드로 제외했습니다(전송 내용 확인).

배포: 재직 중 사내 서버·GPT-4o API로 시범 운영. 공개 데모는 Docker·GitHub Actions·Cloud Run CI/CD.

MCP: 이력 조회·수치 계산 서버를 구현·검증했으나 운영에는 미채택. 모델이 도구 호출 여부를 임의로 정해 생기는 이력 누락·평가 입력 변동을 막기 위해 코드가 조회·계산 순서를 고정합니다.

문서별 품질 검증 기준

분석·발주요청서·이메일마다 기준을 따로 두고, 형식·수치·인용은 **코드**가, 의미·근거·노출은 **LLM**이 검사합니다.

01 분석 검증

ANALYSIS QUALITY CHECKLIST

분석 LLM이 작성하는 **조달 기간·주문량 변경 제안, 담당자·공급처 확인 질문, 권고 후속 조치**를 코드와 별도 LLM Judge로 검증합니다.

차단 항목: 실패 시 피드백으로 최대 2회 재작성. 남은 오류는 초안 상단 임시 메모와 운영자용 평가보고서에 표시합니다.

검토 항목: 재작성 없이 상단 임시 메모로 담당자 확인을 요청합니다.

코드 — 형식과 수치

10 CHECKS

C1	차단	필수 항목·자료형이 출력 규격에 맞는가?
C2	차단	입력에 있는 품목만 언급했는가?
C3	차단	주문량 변경이 코드의 권장 수량에서 출발하는가?
C4	차단	제안·질문·후속 조치의 출처를 추적할 수 있는가?
C5	차단	조달 기간·수량 제안이 계산 규칙에 맞는가?
C6	차단	입고 전 소진 예상 품목에 후속 조치가 있는가?
C7	검토	요약에 입고 전 소진 예상 품목이 모두 언급됐는가?
C8	검토	요약이 100단어 이내인가?
C9	차단	본문의 조달 기간·주문량 변경값이 제안과 같은가?
C10	차단	제안 반영 후 재고 수치가 코드 재계산과 같은가?

LLM Judge — 근거와 판단

14 CHECKS

J1a	차단	이력 서술이 실제 문서에 있는가?
J1b	차단	이력 내용을 과장·축소하지 않았는가?
J1c	차단	이력을 맞는 공급업체·품목에 적용했는가?
J2a	검토	이력에서 발견된 공급업체 이슈를 묻는 질문이 있는가?
J2b	검토	이력에서 발견된 품목 이슈를 묻는 질문이 있는가?
J2c	검토	확인 질문이 근거 없는 문제를 전제하지 않는가?
J3a	차단	변경 제안의 방향이 인용한 근거와 맞는가?
J3b	차단	변경 제안의 크기가 근거에 맞는가?*
J3c	차단	근거가 해당하는 모든 품목에 변경을 적용했는가?
J4	차단	본문의 재고 수치가 변경 반영 후 수치와 같은가?
J5	차단	공급처에 보낼 질문에 내부정보가 없는가?
J6	검토	인용 근거가 확인 질문·후속 조치를 뒷받침하는가?
J7	검토	주문 판단에 필요한 이력을 빠짐없이 활용했는가?
J8	검토	확인된 사실과 LLM의 구매 판단을 구분했는가?

각 항목은 검사 대상(변경 제안, 공급처 질문 등)이 있는 경우에만 수행하며, 대상이 없으면 생략합니다. 항목별 판정·사유를 기록하고, 모델 비교·실행 중 검증·SFT 학습용 응답 선별에 같은 기준을 사용합니다.

* J3b: 근거에 크기가 없어 추정한 경우, 추정임을 밝히고 확인을 요청하면 통과합니다.

02 발주요청서·이메일 검증

PURCHASE REQUEST · SUPPLIER EMAIL

발주요청서: 분석 결과를 결재권자용 문장으로 옮길 때 사실·수치를 왜곡하거나 덧붙이지 않았는지 검사합니다. 재작성 없이, 실패한 항목을 발주요청서 상단 임시 메모에 표시합니다.

이메일: 공급처로 나가는 문서라 내부 정보 노출(E1~E3)은 차단 항목으로 둡니다. 실패하면 사유를 피드백으로 최대 2회 재작성하고, 남은 사유는 이메일 상단 임시 메모에 표시합니다. 질문 누락·중복, 긴급 품목 문의, 문체(E4~E7)는 검토 항목으로 메모에 표시합니다.

발주요청서 — 사실·수치 보존

5 CHECKS

P1a · LLM	검토	입력에 없는 사실·평가를 덧붙이지 않았는가?
P1b · LLM	검토	수치를 수식어 없이 그대로 인용했는가?
P1c · LLM	검토	다른 단어로 바꿔 쓴 곳의 의미가 그대로인가?
P2 · 코드	검토	목적 1~2문장, 사유 2~4문장 분량인가?
P3 · 코드	차단	주어진 이력 문서 번호만 인용했는가?

이메일 — 내부 정보 보호·요청 품질

7 CHECKS

E1 · 코드·LLM	차단	내부 용어·재고·위험도·분석을 드러내지 않았는가?
E2 · LLM	차단	공급처의 과거 문제·시점을 언급하지 않았는가?
E3 · 코드·LLM	차단	주문 외 품목을 언급하지 않았는가?
E4 · LLM	검토	확인할 점을 빠짐없이 질문했는가?
E5 · LLM	검토	같은 질문을 반복하지 않았는가?
E6 · LLM	검토	긴급 품목의 조기 출하·납품을 물었는가?
E7 · LLM	검토	발주 약속 없이 정중한 요청 문체인가?

발주요청서·이메일 작성 모델 선정을 위한 비교 테스트에도 같은 항목을 기준으로 사용했습니다. E1~E3은 이메일 검증기(코드 + Claude Haiku)가, 나머지 LLM 항목은 LLM Judge(Claude Haiku)가 판정합니다.

목적별 모델 비교 평가 및 채택

API 모델 평가 출력
약 1,360건
분석·발주요청서·이메일 모델 비교 등

API 모델 검사 판정
약 38,600건
약 6,000회 Judge 호출의 항목별 판정

LLM Judge 오류 검출률
93.9%
분석·발주요청서 검사, 오류 표본 51개 반복 평가

- **후보 설정(GPT·Claude·Gemini 계열의 가격 등급·effort별 조합) → 동일 입력으로 실행 → 사전 정의한 평가 기준으로 판정(코드 검사·LLM Judge: 분석 24개, 발주요청서 5개, 이메일 7개 항목) → 개발자 직접 검토(HITL) → 모델 선정·프롬프트 최종 수정.**
- 평가 기준 통과율뿐 아니라 비용·지연 시간과 실제 출력 문장의 차이를 함께 비교했습니다.
- Judge는 같은 계열의 출력을 선호할 수 있어, 운영에서는 평가 대상과 다른 계열의 모델로 구성했습니다. Judge를 Claude 계열(Haiku)로 정했고 Gemini는 호출 오류로 가용성·안정성 문제가 있어, 발주요청서·이메일 작성 모델은 GPT 계열에서 비교했습니다.

01 분석 모델 — 정확한 수치 계산·구체적 후속 조치 도출 능력

구매 분석 에이전트 비교: 7개 모델·9개 설정, 3라운드. 동일 2개 사례·설정별 2~4회 반복. 시간·비용은 공급업체 1곳 기준. 수치는 조달 기간 변경 후 코드가 다시 계산한 값과 대조.

모델 · effort	시간	호출 비용	수치 정확성 · 확인 질문·후속 조치 검토
gpt-4o	8~14초	$0.039~0.064	수치 오류. 해결된 통관 문제를 현재 지연으로 해석.
gpt-6-luna · medium	21~36초	$0.0015~0.0042	수치 정확. 공급처 확인 질문이 적고, 후속 조치에 기한을 명시하지 않음.
gpt-6-luna · high	37~94초	$0.0022~0.0042	medium보다 느리고 구체성 차이 없음. 실행 시간 60초 제한 초과 3회.
claude-sonnet-5-5 · high	20~31초	$0.039~0.109	수치 정확. medium보다 느리고 비용 높음.
claude-sonnet-5-5 · medium	10~22초	$0.026~0.046	수치 정확. 담당자·공급처 확인 질문 다양. Sol 대비 고비용.
gemini-3.5-flash-lite	—	—	Google 서버 과부하 오류(503)로 1회 실행 중 1회 호출 실패.
gemini-3.6-flash	34초	$0.031	4회 중 3회 503 오류. 성공 1회는 수치 정확·조치 일반적. 가용성 문제로 제외.
gemini-3.8-flash	—	—	짧은 테스트 요청 3회 중 2회 오류(503·504), 1회는 169초로 60초 제한 초과.
gpt-6.1-sol · medium	23~39초	$0.021~0.033	수치 정확. 담당자 후속 조치와 발주·대체 입고 기한 명시.

Sol medium 선정: 구체적인 구매 후속 조치·기한, claude-sonnet-5-5 · medium 대비 낮은 비용을 고려했습니다. 분석은 GPT, Judge는 Claude(Haiku)로 구성해 같은 계열 출력을 선호할 가능성을 피했습니다. Gemini는 일주일간 세 차례 시도에서 모두 503 과부하·응답 지연이 반복되어 서버 가용성·안정성을 고려해 제외했습니다.

02 LLM Judge — 누락 없는 오류 검출·일관된 판정 능력

분석·발주요청서 Judge 비교: 오류를 심은 표본 51개를 3회 반복 평가하고 개발자 판정 89건과 대조. 사전 기준: 검출률 ≥ 90%, 오탐률 ≤ 10%, 판정 변동률 ≤ 5%.

Judge 설정	오류 검출률	판정 변동률	오탐률	판정 1회 비용	시간
gpt-6-luna	89.1%	—	17.0%	$0.0020	34초
gemini-3.1-flash-lite	요청 한도 초과 오류(429)로 판정 61% 무응답. 응답한 표본의 오류 검출률도 40.4%.				
claude-haiku-5-5 · 강제 도구 호출(추론 없음)	83.7%	17.6%	2.7%	$0.0018	6초
claude-haiku-5-5 · medium	91.2%	5.9%	9.5%	$0.0018	12초
claude-haiku-5-5 · high	93.9%	3.9%	8.0%	$0.0024	16초

미탐지와 오탐 중 우선순위: 놓친 오류(미탐지)는 아무 표시 없이 문서에 남아 담당자와 결재권자가 잘못된 수치·사실을 믿고 발주량·시점을 결정할 수 있습니다. 반면 오탐은 상단 임시 메모에 표시되어 담당자가 확인하는 시간만 듭니다. 그래서 **약간의 오탐을 감수하더라도 오류를 놓치지 않는 데 우선순위를 뒀습니다.**

Haiku high 선정: 사전 기준을 모두 충족한 유일한 설정이며, 오류 검출률이 가장 높습니다. 판정 형식을 강제하는 도구 호출 방식에서는 Haiku가 추론 없이 답해, 추론하는 luna와 조건이 달랐습니다. 이를 발견해 추론 후 답하도록 바꾸자 검출률이 83.7%에서 93.9%로 올랐습니다.

발주요청서·이메일은 분석 결과를 옮겨 쓰는 역할이라, 추론 성능보다 **문서 목적에 맞게 문체를 바꾸되 사실·수치를 왜곡하거나 덧붙이지 않는지**를 기준으로 비교했습니다. 같은 입력 25건에 effort를 명시하고, 코드·Judge 판정 뒤 출력을 모두 직접 읽었습니다.

03 발주요청서 작성 — 사실 및 수치 보존 능력

발주요청서 작성 비교: 결재권자가 읽는 목적·근거 문단. 코드 검사(문장 수·인용), Judge(내용 추가·판단 표현·과장), 직접 검토. gpt-4o·gpt-5.4-mini는 2라운드, 나머지는 최종 5라운드 결과. 건수는 출력 25건 중 문제가 있었던 건수입니다.

모델 · effort	직접 검토 시 문제 건수	Judge 판정 시 문제 건수	시간	요청당 비용	직접 검토 세부 사항
gpt-4o	22	19	2.8초	$0.0047	공급처 평가를 임의로 추가("proven track record"), 수치 오류.
gpt-5.4-mini · none	18	6	2.0초	$0.0018	시스템 용어(pipeline)·없는 수정(revised)·잘못된 인용, 조치 누락.
gpt-5.4-mini · low	19	15	2.8초	$0.0023	시스템 용어·없는 수정·빈 괄호, 확인 순서 변경.
gpt-6-luna · none	7	2	3.6초	$0.0002	요청 외 품목 언급, 입력 논평, 입고 기한을 납기로 기재.
gpt-6-luna · low	6	3	4.1초	$0.0003	품질 문제를 공급처 탓으로, 발견 사항 뒤바꿈, 빈도 약화.
gpt-6-luna · medium	4	4	10.3초	$0.0006	품질 문제를 공급처 탓으로, 입고 기한을 납기로, 빈도 약화.
gpt-6.1-sol · medium	0	0	12.8초	$0.0076	사실·수치·조건을 그대로 옮김.
gpt-6.1-sol · low	0	1	5.3초	$0.0056	사실·수치·조건을 그대로 옮김. Judge 1건은 더 엄격한 해석.

Sol low 선정: low·medium 모두 직접 검토에서 문제 0건이고, low가 시간은 절반 이하, 비용은 약 3/4입니다. 문장 수 규칙 준수율 1위였던 gpt-5.4-mini(24/25)도 직접 읽은 뒤 제외했습니다. 지표만으로는 고를 수 없었던 사례입니다.

04 이메일 작성 — 내부 정보 보호와 과거 문제 간접 확인 능력

이메일 작성 비교: 최종 3라운드, 같은 입력 25건. 출력 25건 중 문제 건수. 코드 검사(E3 다른 품목 언급), Judge 판정(E1·E2·E4~E7: 내부 정보 노출, 과거 문제 언급*, 확인 사항 누락·중복, 긴급 품목 출고일 문의, 어조), 직접 검토. Judge는 같은 이메일을 3회 판정해, 항목별로 2회 이상 실패하면 실패로 집계했습니다. 내부 정보(재고·위험도·내부 검토) 노출은 모든 설정에서 0건이라, 차이는 과거 문제를 묻는 방식*에서 났습니다.

모델 · effort	직접 검토 시 문제 건수	Judge 판정 시 문제 건수	시간	이메일당 비용
gpt-5.4-mini · none	7	6	2.4초	$0.0010
gpt-5.4-mini · low	6	6	2.5초	$0.0013
gpt-6-luna · none	3	3	2.3초	$0.0001
gpt-6-luna · low	1	2	3.4초	$0.0002
gpt-6-luna · medium	0	2	5.2초	$0.0003
gpt-6.1-sol · medium	0	0	5.0초	$0.0033
gpt-6.1-sol · low	0	0	3.3초	$0.0024

* 같은 확인 사항(1월 배치의 단자 풀림 문제)을 gpt-5.4-mini는 "whether the loose-terminal issue in the January PowerModuleZ batch was isolated"로 그대로 묻고, luna(none)는 시점·배치는 뺐지만 "the cause of the loose-terminal failure"로 문제 자체는 그대로 언급했으며, Sol low는 "how terminal integrity will be verified for the items listed above"로 과거 문제를 직접 언급하지 않고 이번 주문에 대한 질문으로 풀어냈습니다.

Sol low 선정: 직접 검토와 Judge 모두 문제가 0건인 Sol low·medium 중 더 빠르고(3.3초), 공급처의 과거 문제를 드러내지 않고 묻습니다. 이메일은 공급처당 1통이라 luna 대비 비용 차이는 100곳당 약 $0.21입니다.

05 이메일 검증기 — 위반 검출을 유지하며 정상 이메일 오탐을 줄이는 능력

이메일 검증기 비교: 검출은 실제 위반 13건과, Sol low의 정상 이메일에 위반을 하나씩 넣은 64건으로 측정. 오탐은 7개 작성 설정의 정상 이메일 162건(그중 운영 모델 Sol low가 쓴 25건)으로 측정. 정상·위반은 이메일 평가 7개 항목 기준. Haiku medium의 오탐 8건 중 7건은 과거 공급처 문제를 암시한 표현을 더 엄격하게 해석한 경우였습니다.

검증 모델	실제 위반 검출(13건)	심은 위반 검출(64건)	정상 이메일 오탐률(162건)	Sol low 이메일 오탐률(25건)	시간	검사 1회 비용
gpt-4o-mini	13/13	61/64	55/162 (34.0%)	10/25 (40.0%)	0.8초	$0.00005
claude-haiku-5-5 · low	12/13	61/64	47/162 (29.0%)	8/25 (32.0%)	1.9초	$0.00014
claude-haiku-5-5 · high	11/13	59/64	8/162 (4.9%)	0/25 (0.0%)	2.4초	$0.00021
claude-haiku-5-5 · medium	13/13	60/64	8/162 (4.9%)	0/25 (0.0%)	2.2초	$0.00018

Haiku medium 선정: 후보 모두 실제 위반을 거의 다 잡아 차이는 오탐에서 났습니다. 오탐은 정상 이메일을 재작성으로 되돌려 보내는데, gpt-4o-mini는 정상 162건 중 55건(34%)을 실패로 판정했고 Haiku medium은 8건(4.9%)이었으며, Sol low가 쓴 이메일에서는 오탐이 없었습니다. Haiku high는 오탐 수는 medium과 같지만 위반 2건을 놓쳤고, 시간·비용도 더 높았습니다.

자체 호스팅 실험과 업무 품질 검증

자체 호스팅은 ① **서빙 성능(메모리·처리량)**과 ② **출력물 품질**을 따로 측정해 운영 모델 교체 여부를 판단했습니다.

01 서빙 성능 및 출력물 품질 측정

① 서빙 성능: vLLM 메모리·처리량 기준

RTX 5090 1장 · Gemma 4 12B. 모델 품질과 별개인 인프라 측정이라 학습 전 모델로, 실제 분석 요청에서 bf16·FP8을 비교했습니다.

측정	bf16	FP8
가중치·런타임 메모리	23.9 GiB	13.3 GiB
출력 처리량 · 16요청 합산	453.5 tok/s	834.5 tok/s
차단 검사 통과 · 25건	14~15/25	13/25

메모리 약 **44% 절감**, 동시 요청 16개에서 처리량 약 **1.84배**.
품질 차이는 반복 실행 편차 수준이었습니다(통과 FP8 13/25, bf16 14·15/25; bf16 반복 판정 변동 3건). FP8은 1회만 실행해, 이 정도 통과 건수 차이로는 품질 차이를 단정할 수 없습니다. FP8에서만 생긴 실패는 주로, 이력 문서에 조달 기간을 늘릴 사유는 있지만 몇 주 늘지는 없을 때(예: 종료일 미정 파업), 모델이 예상한 조달 기간 변경 폭(+4주)을 "추정·확인 필요"로 밝히지 않은 경우(J3b)로, 판단 오류는 아니었습니다.

② 출력물 품질: QLoRA SFT 전후 측정

오픈웨이트 5종 중 **Gemma 4 12B** 선정. 검사 통과 합성 응답 98건(학습 85·검증 13)을 확보하고, **학습 데이터 25·50·85건 × 시드 2개, 총 6회** QLoRA SFT를 수행했습니다.

검증 손실 · 25→85건 학습, 시드 평균 **0.452 → 0.328**

차단 검사 통과 · 학습 전 → SFT 후(6회 범위) **14/25 → 3~10/25**

배운 것: 새 주문이 도착하기 전에 재고가 바닥나는 품목은 공급처에 긴급·분할 납품 가능 여부를 물어야 합니다. Sol은 이런 사례 18건 모두에서 물었고, 학습 전 Gemma는 2번만 물었는데, 학습 후 19~21번으로 늘었습니다.
그런데 그 질문에 내부 조치에 쓰던 문구를 섞어, 공급처에 보낼 문장에 **우리 재고가 몇 주 비는지**를 적었습니다. 예: "...CircuitBoardA **to bridge the 8-week gap**...". 공급처가 우리의 다급함을 알면 가격·배정 협상에서 불리해지는 내부정보라 J5에서 차단됩니다.

02 SFT 실패 원인 추적 — 내부 조치 표현의 공급처 질문 혼입

저장된 모델 출력과 검사 판정 사유를 대조해 필드 간 표현 혼입을 확인했습니다. 내부용 후속 조치 문장에 쓰던 "n주 재고 공백을 메운다"는 표현이 공급처에 보낼 질문에도 그대로 들어갔습니다.

모델 · 입고 전 소진 예상 품목이 있는 평가 18건	긴급·분할 납품을 묻는 공급처 질문 수	그중 재고 공백 기간을 노출한 질문 수
운영 모델 Sol	18	0
학습 전 Gemma	2	2
SFT 후 Gemma · 85건 학습, 시드 1	21	20
SFT 후 Gemma · 85건 학습, 시드 2	19	15

학습에서 제외한 동일 생성기의 검증 13건에서도 모든 차단 검사 통과는 학습 전 3건, SFT 후 2·4건으로 일관되게 개선되지 않았습니다. 관측된 실패 패턴과 분포 영향을 확인했으며, 모델 규모나 데이터량만을 단일 원인으로 단정하지 않았습니다.

운영 결정: gpt-6.1-sol 유지. 첫 응답의 모든 차단 항목 통과 여부로 품질을 비교했습니다. 서빙은 L4 한 장 규모(FP8 13.3 GiB)로 가능함을 확인했지만, 오픈웨이트 모델은 학습 전(14/25)·SFT 후(3~10/25) 모두 기존 운영 모델 gpt-6.1-sol(24/25)에 미달해 교체하지 않았습니다.

향후 과제: 추론 모드로 여러 번 생성한 출력 중 운영 검사를 통과한 것만 추론 과정과 함께 학습시키는 방식(rejection sampling fine-tuning)을 검토합니다. 변경 후 수치 계산 오류와 다른 모델 문장의 혼입을 함께 줄이는 것이 목표입니다.

TECH STACK Python · FastAPI · LangGraph · LangSmith · OpenAI / Anthropic API · ChromaDB · MCP · QLoRA / SFT · vLLM · Docker · GitHub Actions · GCP Cloud Run